Universidade Federal do Agreste de Pernambuco

Equidade na Detecção de Fraudes Financeiras

Impacto do Viés Estrutural e Avaliação de Mitigação

Lucas Victor Dos Santos Gomes · Felipe Mendes Soares Silva
Pedro Tobias Souza Guerra · Ricardo Martins da Silva

Disciplina: Aprendizado de Máquina | Docente: Prof. Dr. Luis Filipe Alves Pereira

O Problema da Reprodução do Viés

Mecanismo de propagação da disparidade em sistemas de detecção de fraudes:

01 Dados Históricos

Modelos herdam os vieses sociais previamente embutidos nos registros de transações.

→

02 Associação Estatística

O Ramo de Atividade do usuário torna-se um proxy para a classificação de fraude.

→

03 Impacto Desproporcional

Clientes legítimos pertencentes a grupos minoritários sofrem bloqueios sistêmicos indevidos.

Conceitos fundamentados em Barocas & Selbst (2016) e Zhang & Harman (2021).

A Pergunta de Pesquisa (PQ)

Investigando a relação entre a mitigação in-processing e o desempenho preditivo:

O Foco Central do Projeto

A partir de um conjunto fixo de atributos, como a aplicação do Prejudice Remover afeta a relação entre a Equidade (|SPD|) e a Eficiência (F1-Score) sob diferentes níveis de viés estrutural nas séries PD e GS?

Neste cenário, qual a penalidade (η) ideal?

Pergunta baseada no estudo de "Ignorance and Prejudice" in Software Fairness (Zhang & Harman, 2021).

Desenho Experimental

Metodologia de avaliação cruzada entre bases controladas:

01

Bases Sintéticas

Uso de 10 bases (séries PD e GS) com viés estrutural controlado (0 a 1).

02

Atributos

Extração de 10 features comportamentais. Uso de Z-scores intra-grupo.

03

Avaliação

Validação cruzada. Avaliação da relação entre F1-Score e |SPD|.

Aprovação da transação é considerada o resultado favorável para o cálculo de equidade.

Mitigação: Prejudice Remover

Aplicação de justiça algorítmica através do regularizador in-processing:

$$\mathcal{L}_{PR} = \mathcal{L}_{CE} + \eta \cdot R_{PR}$$

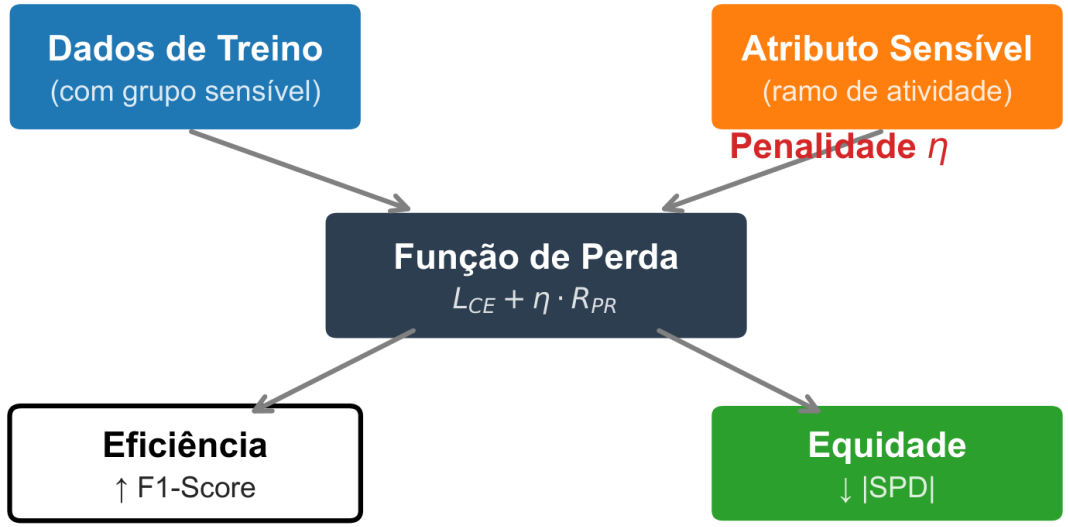

Atuação do Regularizador

O termo atua penalizando a correlação estatística entre as predições de probabilidade e o grupo sensível.

A Escolha do Parâmetro (η)

Valores elevados forçam independência estatística rigorosa, o que reduz substancialmente o F1-Score do modelo.

Equação da função de perda modificada, introduzida originalmente por Kamishima et al. (2012).

Análise Inicial: Viés nas Bases

Avaliação de base: A disparidade prévia injetada na série PD atinge escala severa (|SPD| = 0.87).

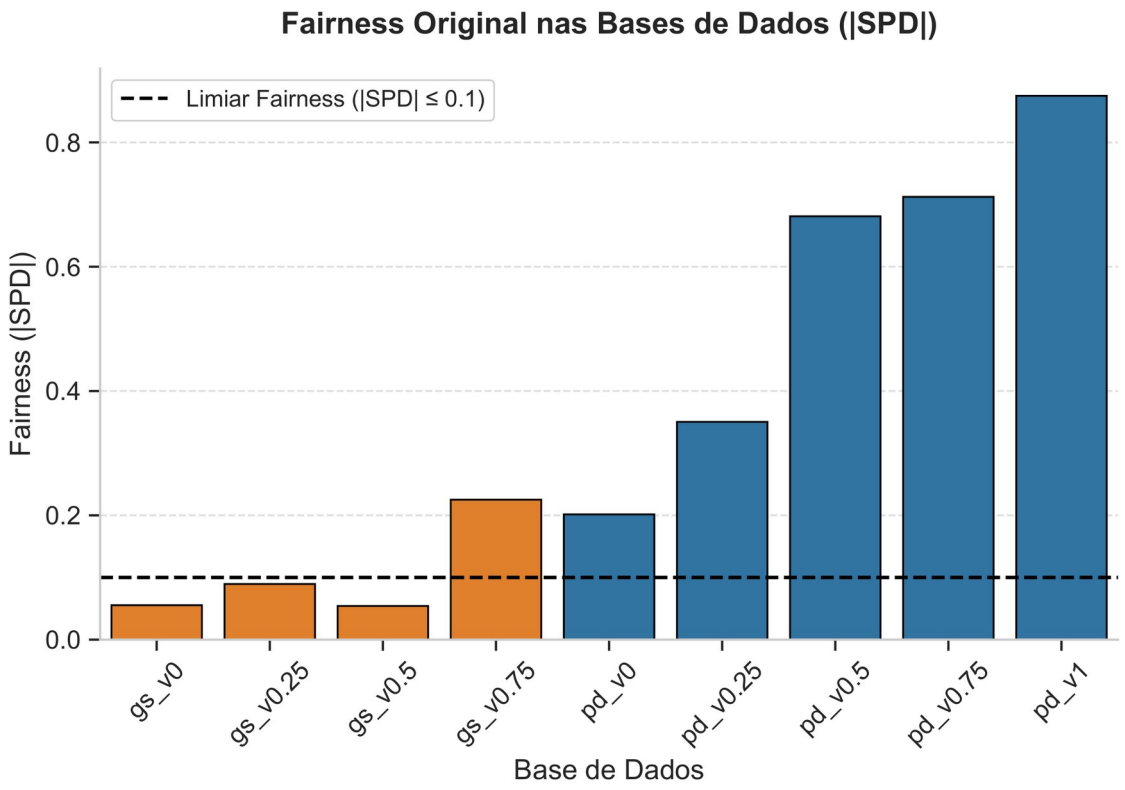

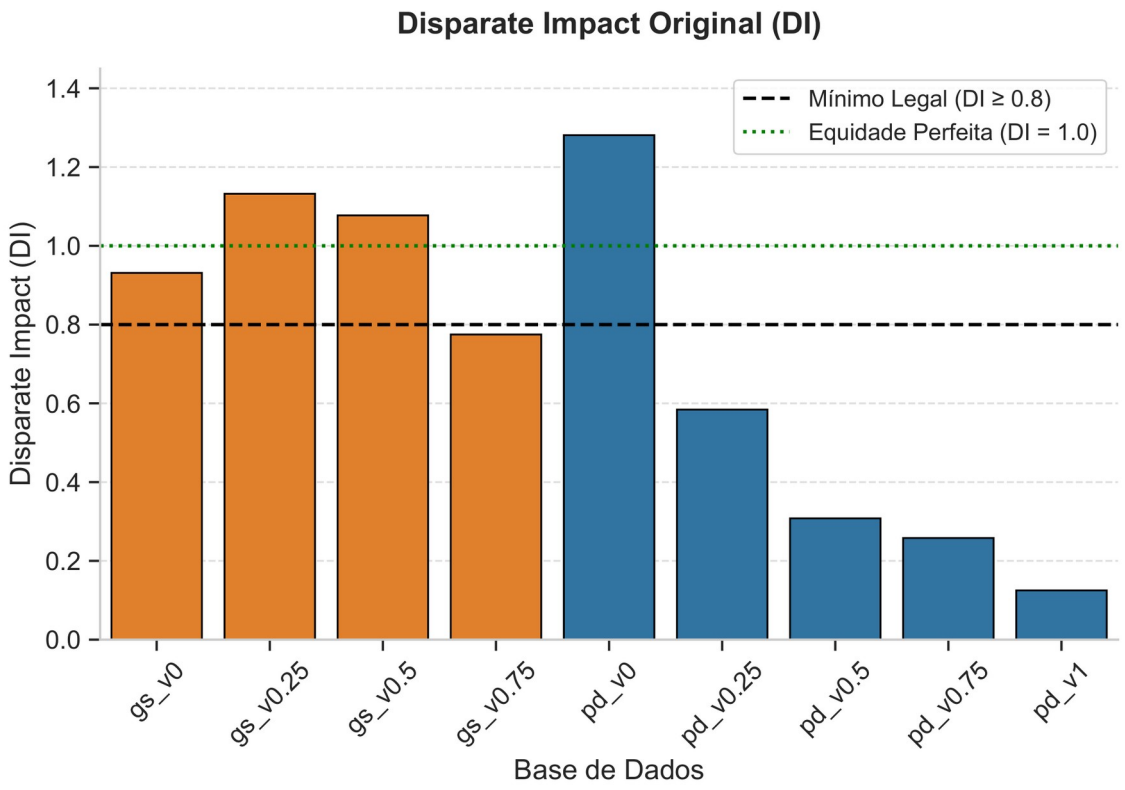

As bases foram sinteticamente manipuladas. A base gs_v1 possui apenas um grupo sensível.

A Relação entre Eficiência e Equidade

A elevação da penalidade (η) diminui a disparidade (|SPD|), mas impacta negativamente o F1-Score.

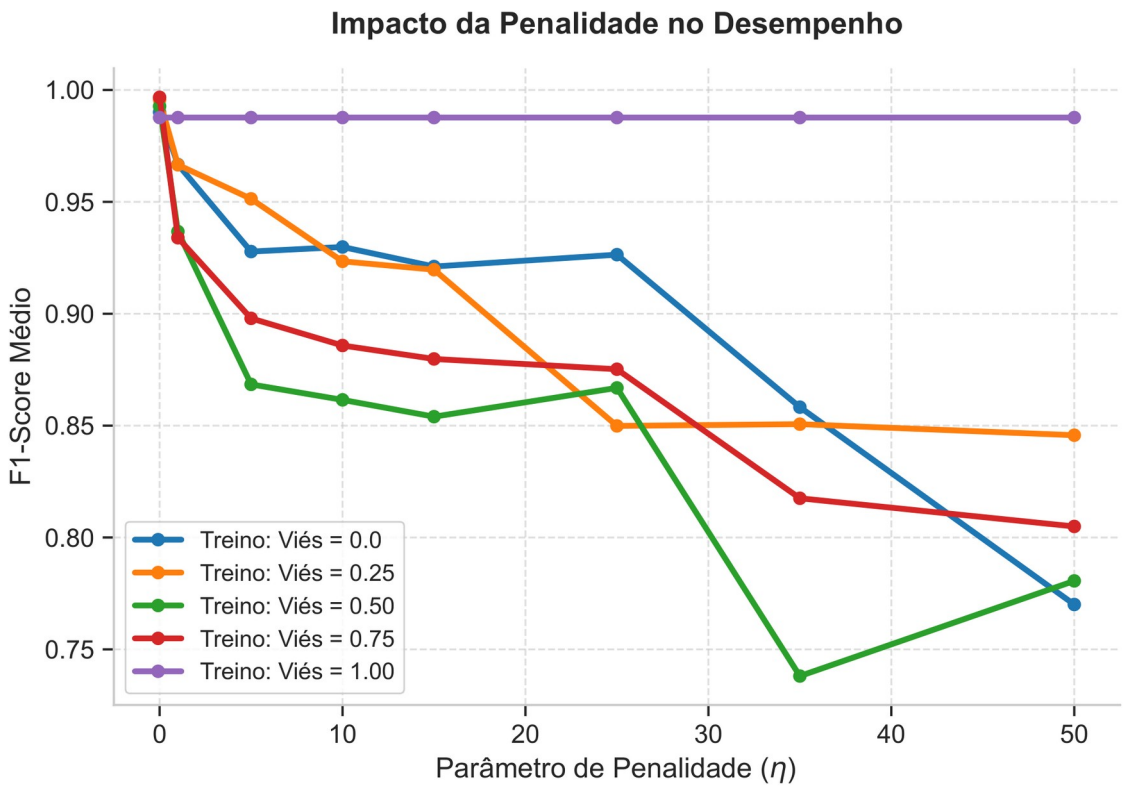

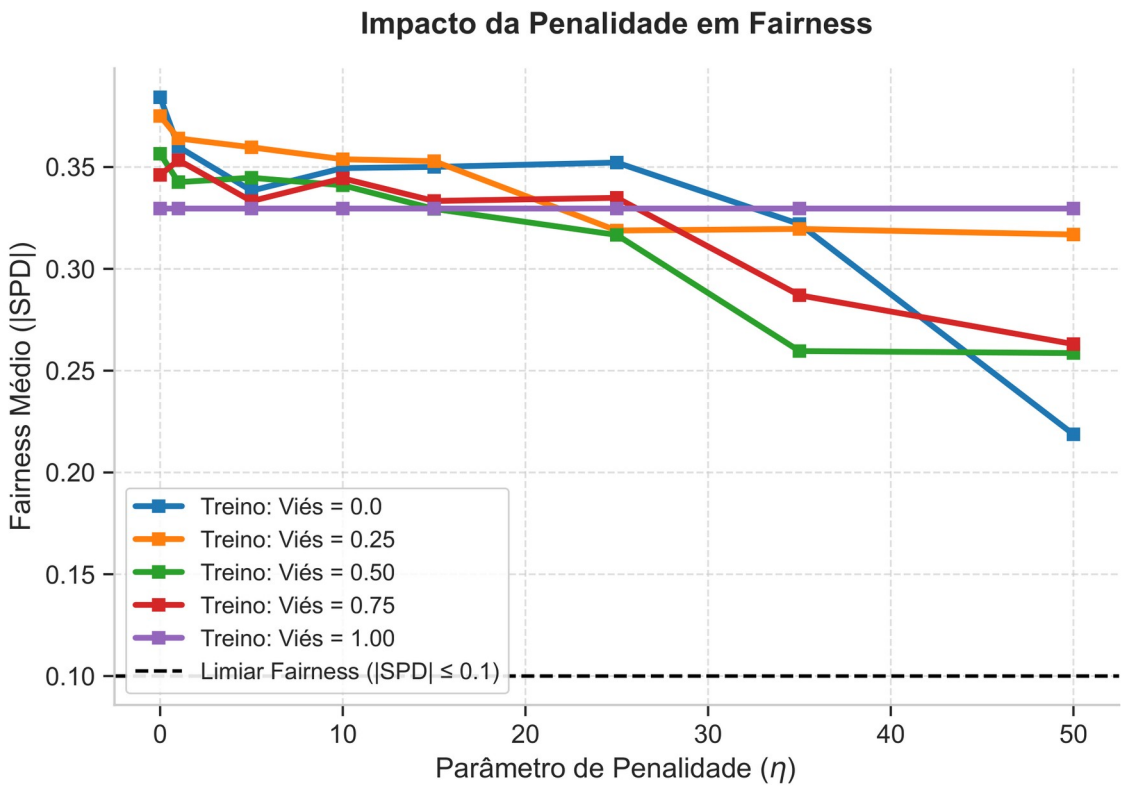

O limite legal de aceitação (DI ≥ 0.8) é representado pela linha pontilhada inferior nas imagens.

Degradação e Definição do η

A métrica de Recall resiste melhor à penalização. Definimos η=10 como ponto de operação para testes.

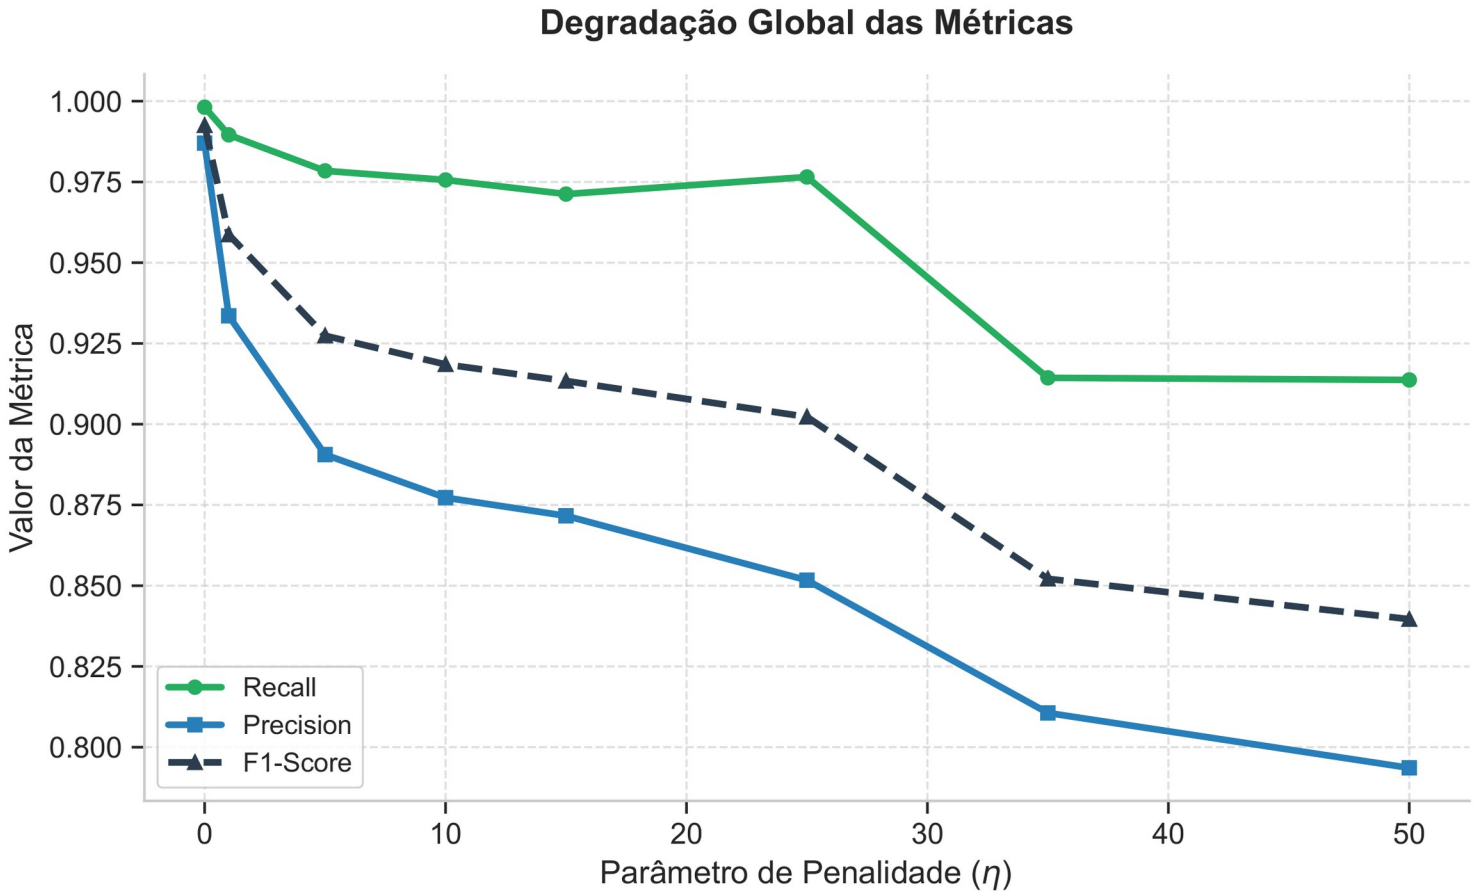

Gráfico de degradação global comparando métricas puras de classificação.

Sensibilidade ao Viés de Treinamento

A eficácia da mitigação não é uniforme; ela varia com a intensidade do viés da base de treino.

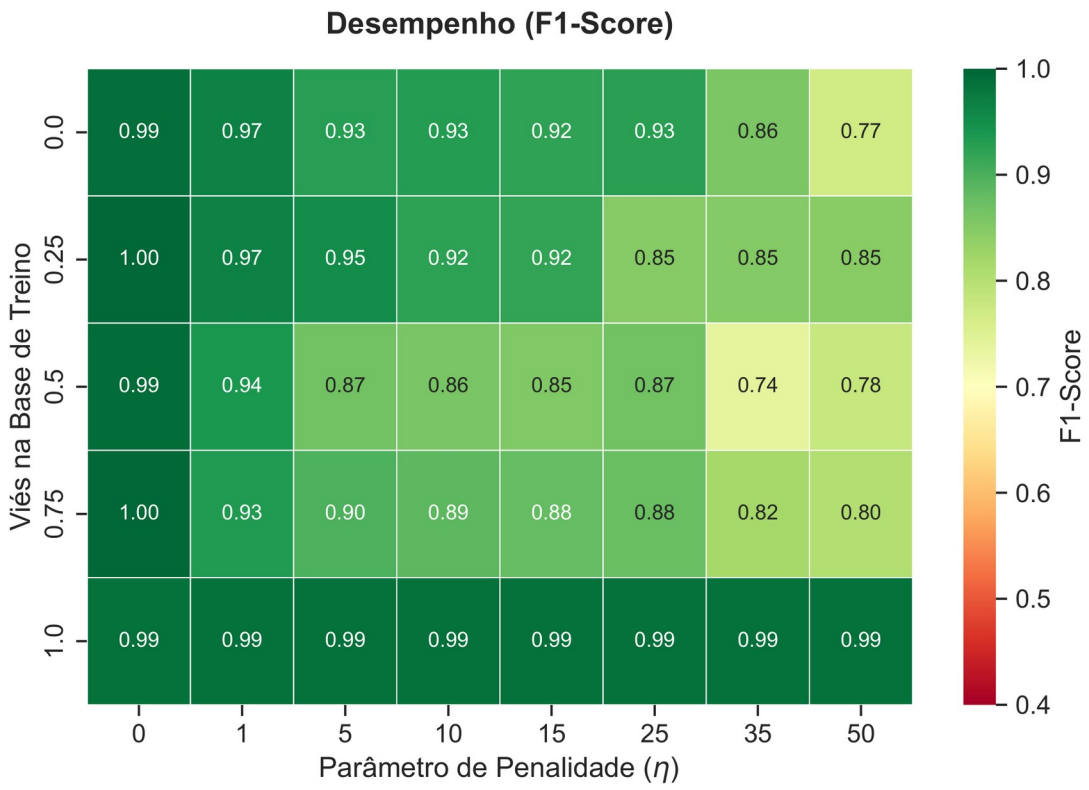

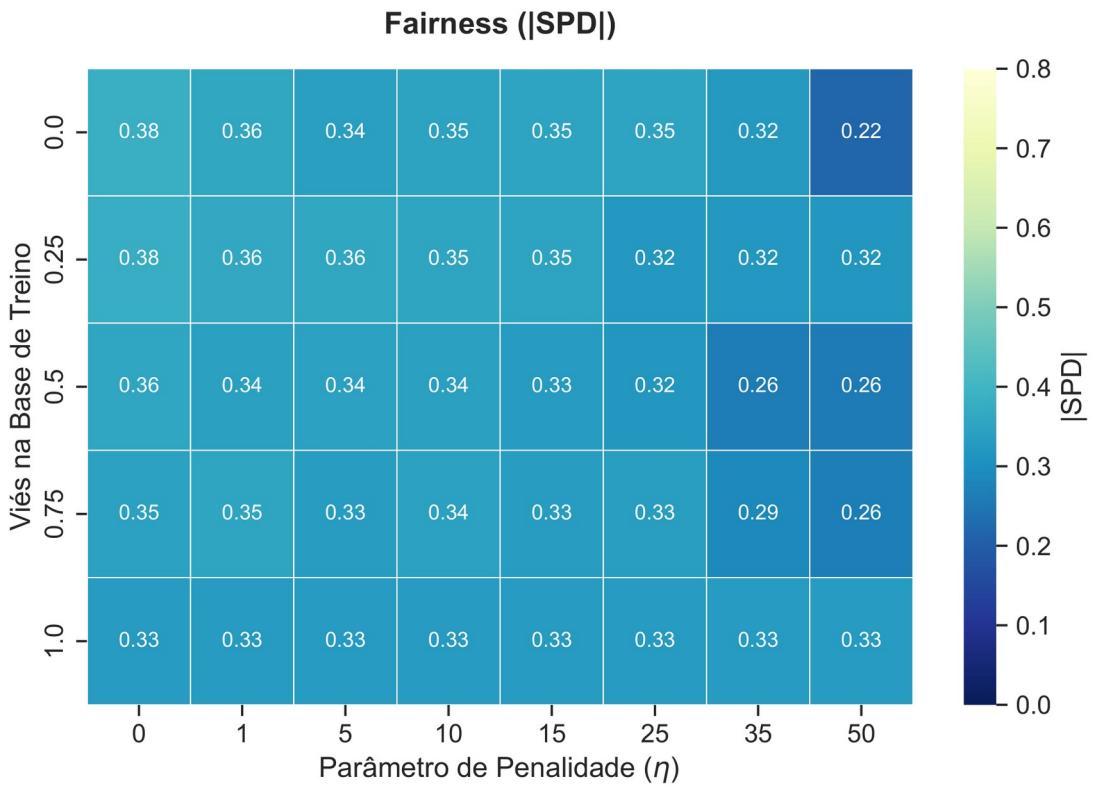

Representação do comportamento do modelo em células de correlação cruzada (heatmap).

Transferência do Viés Aprendido

A mitigação não generaliza de forma estável quando testada em cenários com distorções não familiares.

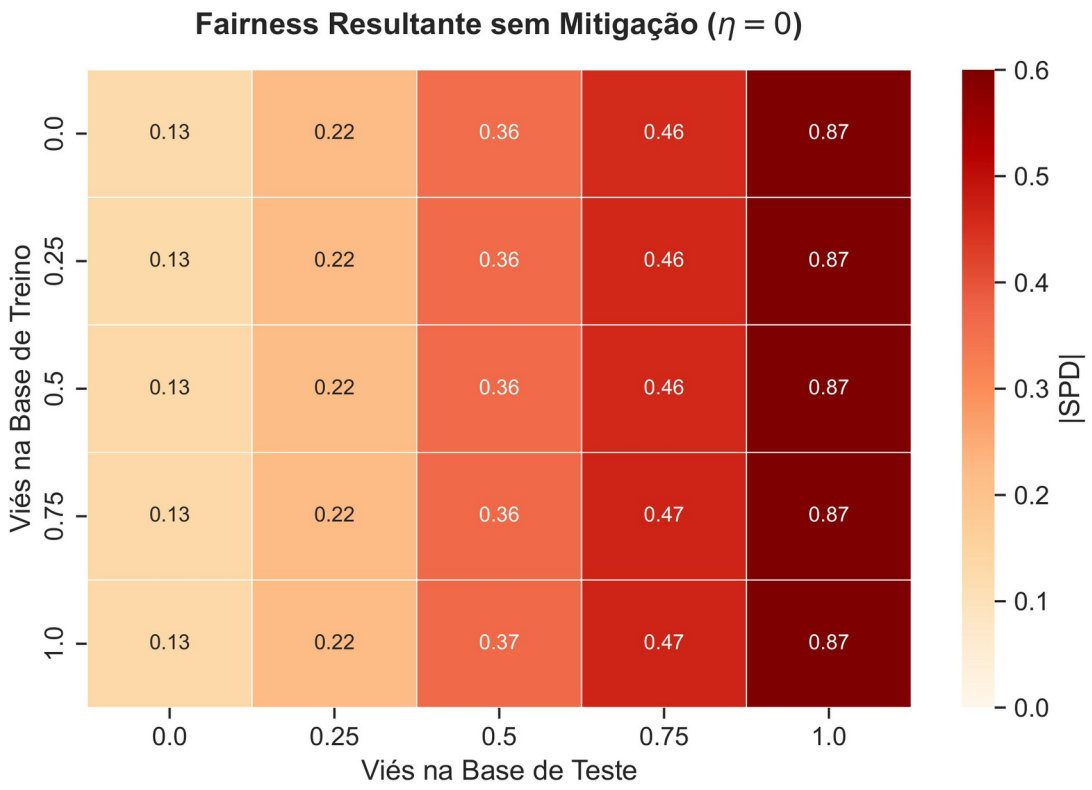

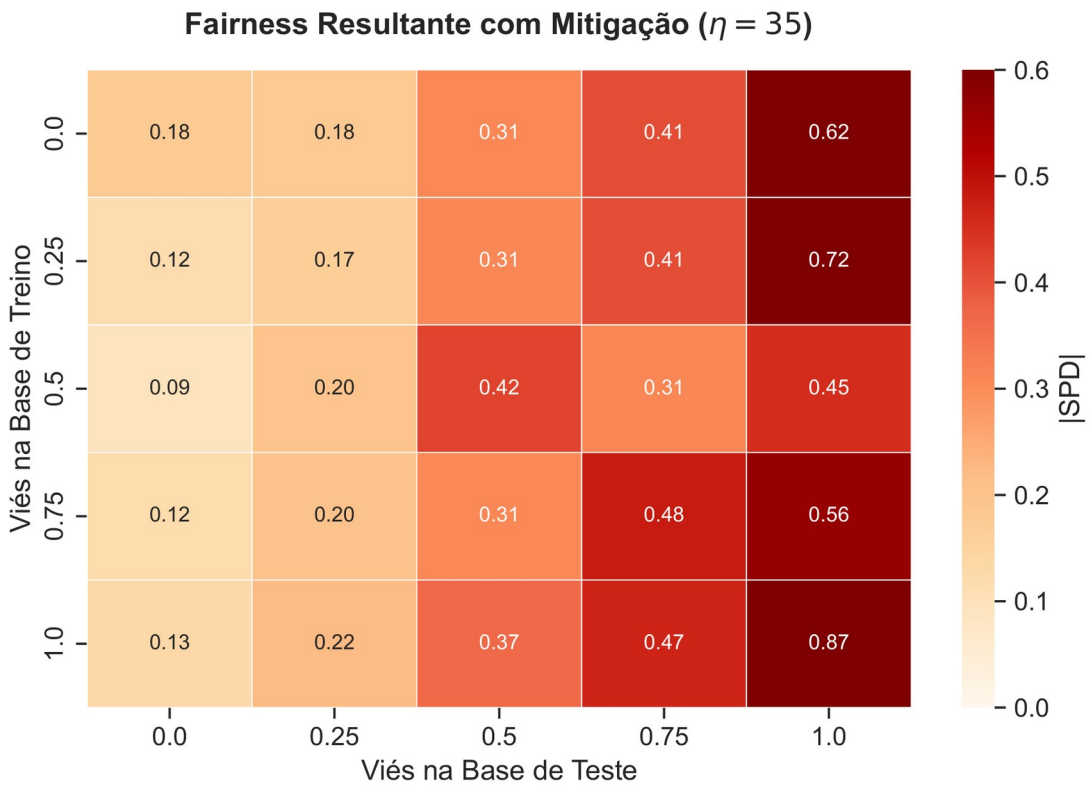

Eixo Y (Base treinada) cruzado com Eixo X (Base testada). Comparação entre η=0 e η=35.

Experimento 1: Escalonamento de Instâncias

O escalonamento amostral consolida o padrão estatístico do viés nas predições do modelo.

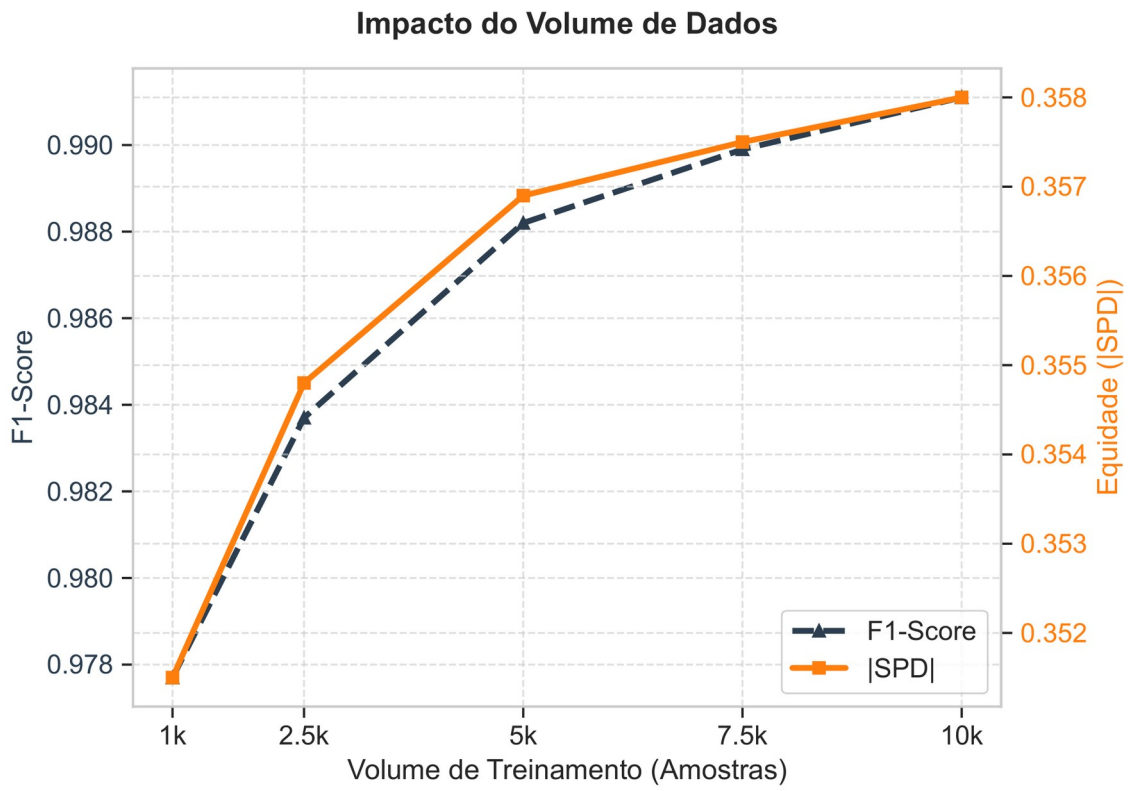

Impacto no |SPD|

O salto amostral gerou ganhos residuais no F1-Score, mas elevou a disparidade (|SPD|) paralelamente.

Comparativo treinando o algoritmo padrão progressivamente de 1.000 a 10.000 amostras.

Experimento 2: Incremento de Atributos

Atributos preditivos rigorosos não são suficientes para dissolver a injustiça inerente ao rótulo.

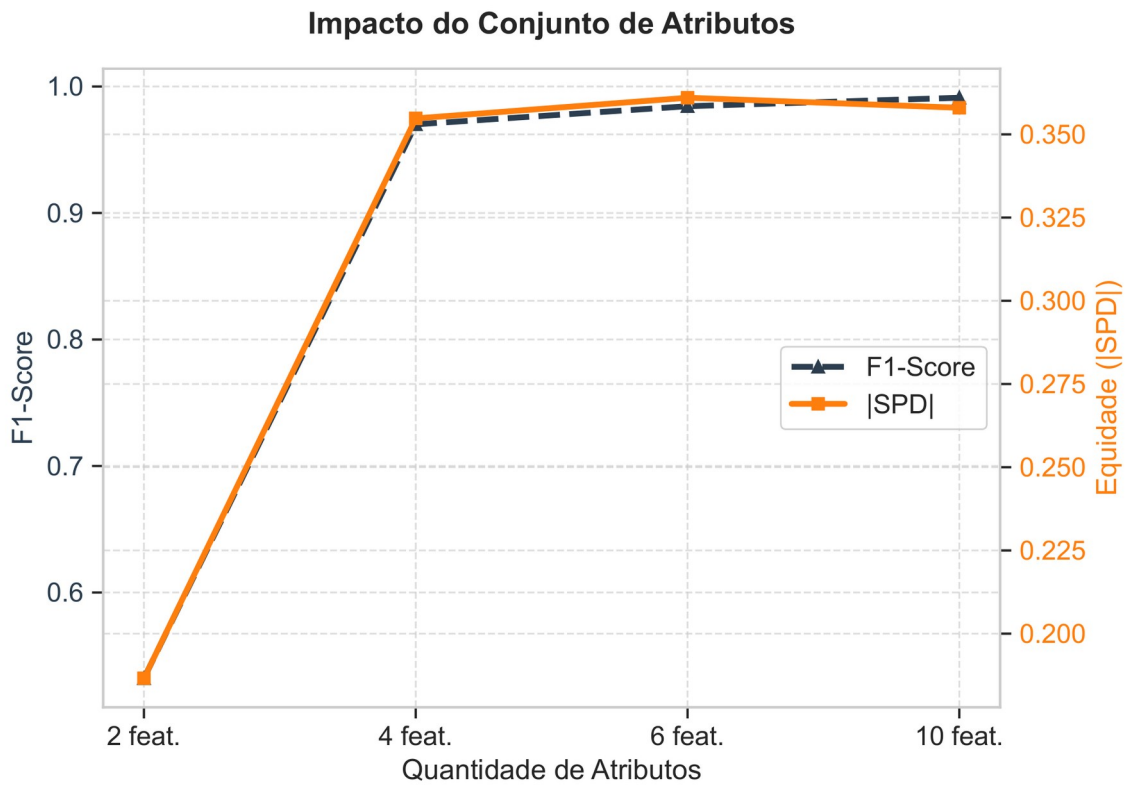

Comportamento do Viés

A inclusão de variáveis comportamentais e temporais (normalizadas via Z-scores) elevou a precisão preditiva, mas travou o |SPD| em alta escala.

Inclusão iterativa das 10 variáveis preditivas contextuais focadas no comportamento da transação.

Experimento 3: Comparação de Métodos

Técnicas convencionais de pré-processamento demonstram ineficácia contra vieses estruturais.

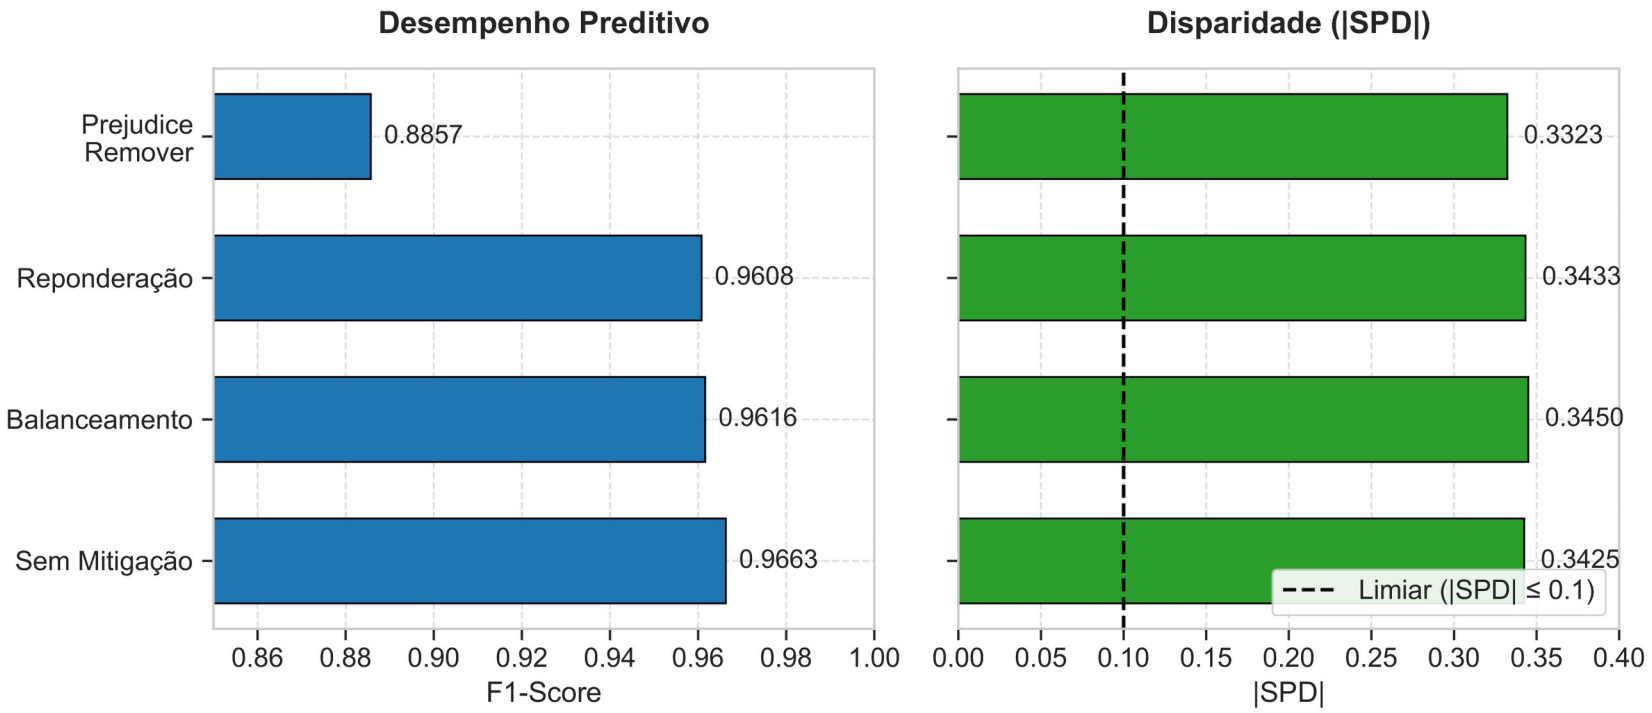

Eficácia da Mitigação

O rebalanceamento de classes e a reponderação tiveram impacto quase nulo no |SPD|.

Somente o Prejudice Remover quebrou a correlação estrutural.

Avaliação com a Base 10.000 amostras. Comparação do Prejudice Remover contra métodos de dados.

Conclusões do Projeto

Síntese dos resultados experimentais e estruturais identificados na detecção:

01 Viés Estrutural

A disparidade enraizada nos rótulos não é corrigida pela generalização do modelo.

02 Impacto no Desempenho

A mitigação via algoritmos in-processing afeta diretamente a capacidade preditiva (F1).

03 Curadoria de Dados

A equidade estrita requer intervenção humana na etapa de coleta e amostragem.

O código-fonte e o pipeline de experimentação do projeto encontram-se abertos para auditoria.

Referências Bibliográficas

[1] Barocas, S., & Selbst, A. D. (2016). Big Data's Disparate Impact. California Law Review, 104, 671-732.

[2] Kamishima, T., Akaho, S., Asoh, H., & Sakuma, J. (2012). Fairness-Aware Classifier with Prejudice Remover Regularizer. Machine Learning and Knowledge Discovery in Databases (ECML PKDD), 35-50.

[3] Zhang, J. M., & Harman, M. (2021). "Ignorance and Prejudice" in Software Fairness. 43rd IEEE/ACM International Conference on Software Engineering (ICSE), 1436-1447.

[4] Gomes, L. V. D. S., Silva, F. M. S., Guerra, P. T. S., & Silva, R. M. (2026). am-project: Equidade na Detecção de Fraudes Financeiras. Repositório Público: github.com/lucasvictoor/am-project