Equidade na Detecção de Fraudes Financeiras: Impacto do Viés e Mitigação

Lucas Victor Dos Santos Gomes[1], **Felipe Mendes Soares Silva**[1], **Pedro Tobias Souza Guerra**[1], **Ricardo Martins da Silva**[1]

[1]Universidade Federal do Agreste de Pernambuco (UFAPE)
Garanhuns – PE – Brazil

{lucas.vsgomes, felipe.mendess}@ufape.edu.br
{pedro.tsguerra, ricardo.msilva4}@ufape.edu.br

Abstract. *When a machine learning model judges whether a financial transaction is fraudulent, accuracy alone is insufficient: the model must also be fair. A biased model may flag transactions from certain business sectors as suspicious far more often than others, systematically harming specific customer groups. This work investigates how bias in training data and modeling choices affect the fairness of fraud detection models. Ten financial transaction datasets organized in two series (PD and GS) were used, in which the degree of bias relative to the sensitive attribute (business sector) is varied in a controlled manner from 0.0 to 1.0. Fairness is evaluated by the SPD and DI metrics; predictive performance is measured by F1-Score. Results show that bias is structural and resistant to the tested techniques: no method reached the DI* $\geq$ *0.8 threshold on average, and increasing training volume marginally amplified bias rather than correcting it. The Prejudice Remover was the only technique capable of perceptibly reducing SPD, though at the cost of a significant drop in F1-Score.*

Resumo. *Quando um modelo de aprendizado de máquina julga se uma transação financeira é fraudulenta, a precisão por si só é insuficiente: o modelo também deve ser justo. Um modelo enviesado pode sinalizar transações de determinados setores comerciais como suspeitas com muito mais frequência do que outros, prejudicando sistematicamente grupos específicos de clientes. Este trabalho investiga como o viés nos dados de treinamento e as escolhas de modelagem afetam a equidade de modelos de detecção de fraudes em transações financeiras. Dez bases organizadas em duas séries (PD e GS) foram utilizadas, com grau de viés controlado entre 0.0 e 1.0 em relação ao atributo sensível ramo de atividade. A equidade é medida pelas métricas SPD e DI; o desempenho preditivo, pelo F1-Score. Os resultados mostram que o viés é estrutural e resistente às técnicas testadas: nenhum método atingiu DI* $\geq$ *0.8 em média, e o aumento do volume de dados acentuou marginalmente o viés em vez de corrigi-lo. O Prejudice Remover foi a única técnica capaz de reduzir o SPD de forma perceptível, ao custo de queda expressiva no F1-Score.*

1. Introdução

Com o avanço do aprendizado de máquina e sua inserção em decisões que afetam diretamente a vida de indivíduos, uma preocupação central surgiu no desenvolvimento de

sistemas: o viés algorítmico. Um modelo treinado com dados históricos enviesados tende a reproduzir desigualdades já presentes na sociedade, discriminando grupos minoritários de forma muitas vezes imperceptível para os desenvolvedores [Barocas and Selbst 2016].

Esse conflito entre eficiência e justiça é particularmente evidente na detecção de fraudes em transações financeiras. Um sistema automatizado que classifica uma transação como suspeita impõe uma decisão com consequências diretas ao cliente, incluindo o bloqueio do acesso ao próprio dinheiro. Se o modelo aprendeu padrões a partir de dados que refletem desigualdades históricas, ele tende a associar determinados ramos de atividade comercial a comportamentos fraudulentos com frequência desproporcional, penalizando sistematicamente clientes de certos perfis mesmo quando suas transações são legítimas.

É justamente esse tipo de situação que o trabalho *"Ignorance and Prejudice" in Software Fairness* [Zhang and Harman 2021] coloca em evidência: muitos problemas de equidade em software surgem da falta de atenção às consequências das escolhas técnicas ao longo do desenvolvimento. Os autores argumentam que tanto a ignorância sobre os efeitos dessas escolhas quanto o preconceito embutido nos dados contribuem para que sistemas injustos cheguem à produção. Partindo dessa perspectiva, este trabalho utiliza dez bases de dados de transações financeiras nas quais o grau de viés histórico em relação ao ramo de atividade (`RAMO_ATIVIDADE_1`) foi manipulado de forma controlada. A partir dessas bases, buscamos responder à seguinte pergunta de pesquisa:

> **PQ:** A partir de um conjunto de atributos fixo, como o equilíbrio entre equidade e desempenho preditivo (acurácia) se comporta ao aplicar a técnica *Prejudice Remover* sob diferentes níveis de viés estrutural nas bases de dados? E, nesse cenário, como escolher o parâmetro de penalidade η ideal?

Para garantir a transparência e a reprodutibilidade dos resultados, todo o código-fonte utilizado na extração de atributos, treinamento e avaliação dos modelos foi disponibilizado publicamente em um repositório no GitHub [Gomes et al. 2026].

O restante deste artigo está organizado da seguinte forma: a Seção 2 descreve o pré-processamento, a construção de features e o protocolo de avaliação; a Seção 3 detalha os cenários de avaliação do Prejudice Remover, conjunto de atributos e mitigação; a Seção 4 apresenta os resultados encontrados; a Seção 5 discute o que esses resultados significam em relação a cada pergunta de pesquisa; e a Seção 6 encerra o trabalho com reflexões finais e possíveis direções futuras.

2. Metodologia

Nesta seção descrevemos as bases de dados utilizadas, as etapas de pré-processamento e construção de features, e o protocolo de avaliação adotado.

2.1. Bases de Dados

Trabalhamos com dez bases de dados de transações financeiras, disponibilizadas para este projeto como dados públicos. Elas estão organizadas em duas séries: a série PD, composta pelas bases `pd_v0`, `pd_v0.25`, `pd_v0.5`, `pd_v0.75` e `pd_v1`; e a série GS, composta por `gs_v0`, `gs_v0.25`, `gs_v0.5`, `gs_v0.75` e `gs_v1`. O sufixo numérico de cada base indica seu **nível de viés controlado** ($v \in \{0.0;\ 0.25;\ 0.5;\ 0.75;\ 1.0\}$), onde

$v = 0$ representa a ausência de viés introduzido e $v = 1$ corresponde ao nível máximo. Essa estrutura permite estudar sistematicamente como o grau de viés presente nos dados de treinamento e de teste afeta a equidade dos modelos.

O **atributo sensível** considerado é o ramo de atividade (`RAMO_ATIVIDADE_1`). Para manter a análise binária, filtramos apenas dois grupos: o **grupo privilegiado** (código 1) e o **grupo desprivilegiado** (código 4, recodificado para 0). A **variável alvo** é `I-d`, onde o valor 1 indica suspeita de fraude e o valor 0 indica transação legítima, sendo este último o resultado considerado favorável nas métricas de equidade.

2.2. Pré-processamento e Engenharia de Features

Os dados são ordenados cronologicamente por titular antes de qualquer transformação, evitando vazamento de informação futura (*data leakage*). A partir dos registros brutos, construímos dez features divididas em três grupos. O primeiro grupo contém uma **feature binária temporal**: `final_de_semana`, que indica se a transação ocorreu em sábado ou domingo, capturando um padrão comportamental distinto dos dias úteis. O segundo grupo reúne **features de comportamento do titular**, calculadas com *expanding windows* para evitar leakage: `pct_saldo_gasto` (proporção do valor da transação em relação ao saldo disponível), `zscore_valor_no_titular` (z-score do valor em relação ao histórico acumulado do titular), `n_transacoes_dia_tit` (volume acumulado de transações do titular no mesmo dia), `is_cnab220` (indicador de transações do tipo crédito) e `prop_cnab220_tit` (proporção histórica de uso de crédito pelo titular, calculada com *shift* de um período).

O terceiro grupo contém **features de z-score por ramo de atividade**, que neutralizam o efeito do grupo sensível ao medir anomalia relativa ao comportamento típico de cada ramo: `zscore_valor_no_ramo`, `zscore_n_trans_mes_no_ramo`, `zscore_reg_no_ramo` e `zscore_valor_total_mes_no_ramo`. Ao medir o comportamento do titular em relação à média do seu próprio grupo, essas features reduzem a dependência do modelo em relação ao ramo como proxy discriminatório.

Antes do treinamento, apenas as features contínuas recebem padronização via *StandardScaler*. As features binárias (`final_de_semana` e `is_cnab220`) são mantidas em sua escala original. Valores ausentes são substituídos por zero.

2.3. Protocolo de Avaliação

2.3.1. Balanceamento de classes

Como é comum em detecção de fraudes, as bases apresentam forte desbalanceamento de classes. Para os experimentos que utilizam balanceamento, aplicamos subamostragem das classes majoritárias, limitando o conjunto de treinamento a no máximo 10.000 instâncias com até 5.000 por classe.

2.3.2. Validação cruzada entre bases

Adotamos um esquema de **avaliação cruzada entre bases**: cada base serve como conjunto de treinamento uma vez, e o modelo é avaliado em todas as demais. Isso nos permite observar como o viés do conjunto de treinamento influencia o desempenho e a equidade

do modelo quando aplicado a ambientes com diferentes graus de viés. O conjunto de teste é limitado a 20.000 instâncias por base.

2.3.3. Métricas de avaliação

Os modelos são avaliados sob duas perspectivas. Do ponto de vista do **desempenho preditivo**, utilizamos o F1-Score (média harmônica entre precisão e revocação, indicada para dados desbalanceados), a Precisão (proporção de alertas de fraude que eram de fato fraudes) e a Revocação (proporção de fraudes reais corretamente identificadas). Do ponto de vista da **equidade**, considerando a aprovação da transação (classe 0) como o resultado favorável, utilizamos duas métricas. A **SPD** (*Statistical Parity Difference*) representa a diferença entre a taxa de aprovação do grupo privilegiado ($S = 1$) e do grupo desprivilegiado ($S = 0$), com valores próximos de zero indicando maior equidade:

$$\text{SPD} = P(\hat{Y} = 0 \mid S = 1) - P(\hat{Y} = 0 \mid S = 0).$$

O **DI** (*Disparate Impact*) representa a razão entre as taxas de aprovação dos dois grupos, sendo que o critério dos "quatro quintos" considera valores abaixo de 0.8 como indicativos de discriminação sistemática:

$$\text{DI} = \frac{P(\hat{Y} = 0 \mid S = 0)}{P(\hat{Y} = 0 \mid S = 1)}.$$

Todos os experimentos utilizam semente aleatória fixa (`SEED = 42`) e são paralelizados com a biblioteca `joblib` para garantir reprodutibilidade e eficiência computacional.

3. Experimentos

O projeto está organizado em três experimentos complementares, executados a partir de dois scripts principais: `treino.py` e `experimentos.py`.

3.1. Experimento 1 – Análise do Prejudice Remover

Este experimento investiga o impacto do parâmetro η do Prejudice Remover sobre a equidade e o desempenho preditivo, treinando modelos com o conjunto completo de dez features. O **Prejudice Remover** [Kamishima et al. 2012] é uma técnica de mitigação *in-processing* que adiciona um termo de regularização à função de perda da Regressão Logística, penalizando a dependência entre as predições e o atributo sensível:

$$\mathcal{L}_{\text{PR}} = \mathcal{L}_{\text{CE}} + \eta \cdot \mathcal{R}_{\text{PR}},$$

onde $\mathcal{L}_{\text{CE}}$ é a perda de entropia cruzada e $\mathcal{R}_{\text{PR}}$ penaliza a dependência mútua entre predições e grupo sensível. Quando $\eta = 0$, o modelo se comporta como uma Regressão Logística sem nenhuma consideração de equidade; à medida que η cresce, a penalidade por desigualdade aumenta, podendo impactar o desempenho preditivo. Foram testados oito valores de η:

$$\eta \in \{0.0;\ 1.0;\ 5.0;\ 10.0;\ 15.0;\ 25.0;\ 35.0;\ 50.0\}.$$

Quando o Prejudice Remover não converge ou os dados não permitem seu uso adequado (por exemplo, ausência de representação de algum grupo), uma Regressão Logística convencional é utilizada como *fallback*, aplicada apenas sobre as features não sensíveis.

3.2. Experimento 2 – Conjuntos de Features

Este experimento avalia como a composição do conjunto de features afeta a equidade do modelo, fixando um classificador base (Regressão Logística) e variando apenas as features utilizadas. São testados quatro conjuntos organizados em níveis crescentes de informação: **transacional_2** (duas features de contexto individual do titular: `pct_saldo_gasto` e `zscore_valor_no_titular`); **tipo_temporal_4**, que acrescenta contexto temporal e tipo de lançamento (`final_de_semana` e `is_cnab220`); **comportamental_6**, que adiciona padrões de comportamento acumulado do titular (`n_transacoes_dia_tit` e `prop_cnab220_tit`); e **completo_10**, o conjunto completo incluindo as quatro features de z-score por ramo. A hipótese central é que o nível de informação presente nas features influencia diretamente a equidade do modelo: features que capturam comportamento relativo ao grupo sensível tendem a introduzir mais viés, enquanto features que medem desvios individuais em relação ao próprio grupo (z-scores por ramo) tendem a ser mais equitativas.

3.3. Experimento 3 – Métodos de Mitigação

Este experimento compara quatro abordagens de mitigação de viés aplicadas com o mesmo conjunto de features (excluindo `is_cnab220`, cuja presença tornaria a detecção artificialmente fácil): **LR sem mitigação**, Regressão Logística treinada sobre a amostra bruta desbalanceada, servindo como linha de base; **LR balanceado**, Regressão Logística com balanceamento de classes por subamostragem; **LR reponderado**, Regressão Logística com pesos de Kamiran e Calders [Kamiran and Calders 2012], que ajustam a importância de cada amostra com base na combinação do grupo sensível e da classe alvo; e **Prejudice Remover** ($\eta = 10$), técnica *in-processing* com o valor de η identificado no Experimento 1 como o melhor equilíbrio entre equidade e desempenho.

4. Resultados

4.1. Viés Estrutural nas Bases de Dados

Antes de qualquer modelagem, o viés presente em cada base já revela diferenças substanciais entre as séries PD e GS (Figura 1). Na série PD, o abs_SPD cresce de forma contínua de 0.20 ($v = 0$) a 0.87 ($v = 1$), e o DI cai de 1.28 a 0.13: na base mais enviesada, o grupo desprivilegiado recebe predição favorável com frequência oito vezes menor que o grupo privilegiado. Na série GS, o viés introduzido é estruturalmente diferente: abs_SPD oscila entre 0.06 e 0.23, com DI sempre próximo de 1.0 nas versões com menor viés. A base `gs_v1` contém apenas um grupo sensível, inviabilizando o cálculo das métricas de equidade e por isso está ausente dos gráficos desta seção. Esse contraste entre séries impõe um desafio para a generalização dos modelos: um classificador treinado em PD enfrenta distribuições de grupo muito mais assimétricas do que quando treinado em GS.

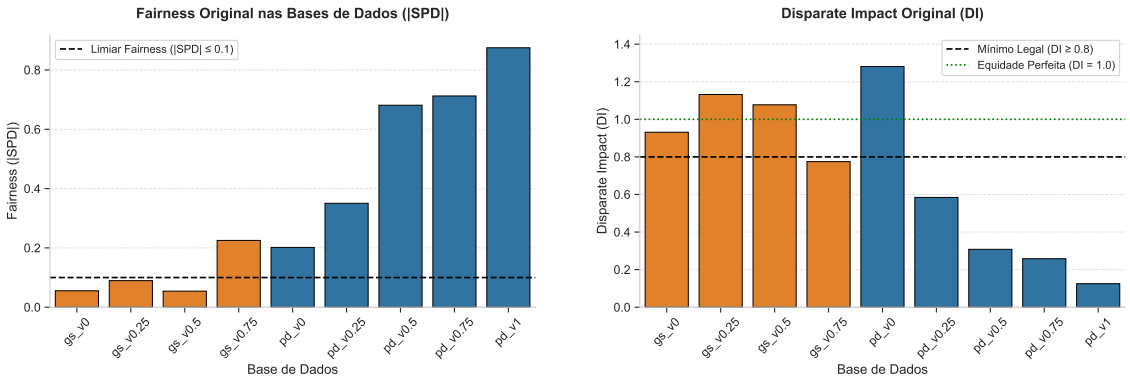

Figura 1. Viés nos dados brutos de cada base (abs_SPD e DI) antes do treinamento, por série e nível de viés controlado. A base `gs_v1` é omitida por conter apenas um grupo sensível, o que inviabiliza o cálculo das métricas de equidade.

4.2. Efeito do Parâmetro η do Prejudice Remover

A Figura 2 apresenta o comportamento de F1 e abs_SPD ao longo da varredura de $\eta \in \{0.0;\ 1.0;\ 5.0;\ 10.0;\ 15.0;\ 25.0;\ 35.0;\ 50.0\}$. Com $\eta = 0$, equivalente a uma Regressão Logística sem penalidade de equidade, o modelo atingiu F1 $= 0.9911$ e abs_SPD $= 0.358$, com DI $= 0.719$. À medida que η cresce, o F1 diminui constantemente: em $\eta = 10$ cai para 0.910; em $\eta = 25$, para 0.894; e em $\eta = 50$, para 0.834. O abs_SPD acompanha essa trajetória com algumas oscilações, atingindo o valor mínimo de 0.278 em $\eta = 50$ (DI $= 0.776$), redução de 22.3% em relação ao modelo base. A regra dos quatro quintos (DI ≥ 0.8) não foi atingida em média para nenhum valor de η.

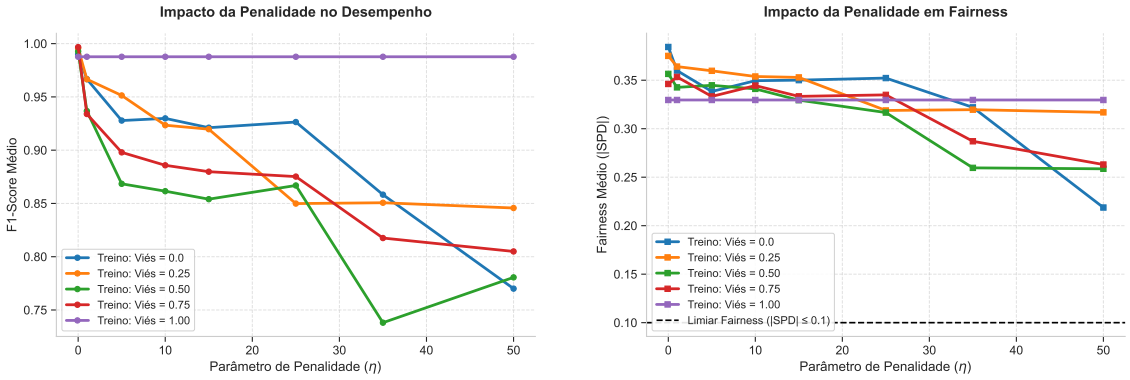

Figura 2. F1-Score e abs_SPD em função do parâmetro η do Prejudice Remover, médias sobre todos os pares treino–teste. Cada curva corresponde a um nível de viés da base de treinamento.

O comportamento diverge acentuadamente entre séries. Na série GS, η elevado produziu ganhos mínimos de equidade: entre $\eta = 0$ e $\eta = 50$, abs_SPD caiu apenas de 0.382 para 0.364 (-4.7%), enquanto F1 caiu de 0.994 para 0.966 (-2.8%). Já na série PD, a resposta ao regularizador foi muito mais intensa: abs_SPD reduziu de 0.334 para 0.190 (-43%), mas F1 sofreu queda de 0.989 para 0.702 (-29%). Exclusivamente na série PD com $\eta = 50$, o DI médio atingiu 0.855, ultrapassando o limiar de 0.8. Os heatmaps da Figura 3 mostram como essa diferença se manifesta nas combinações individuais de bases

de treinamento e teste. As células com maior abs_SPD correspondem a pares nos quais a base de treinamento tem viés elevado e a base de teste tem distribuição de grupos distinta, evidenciando que o modelo aprende e transfere o padrão desigual do dado de origem.

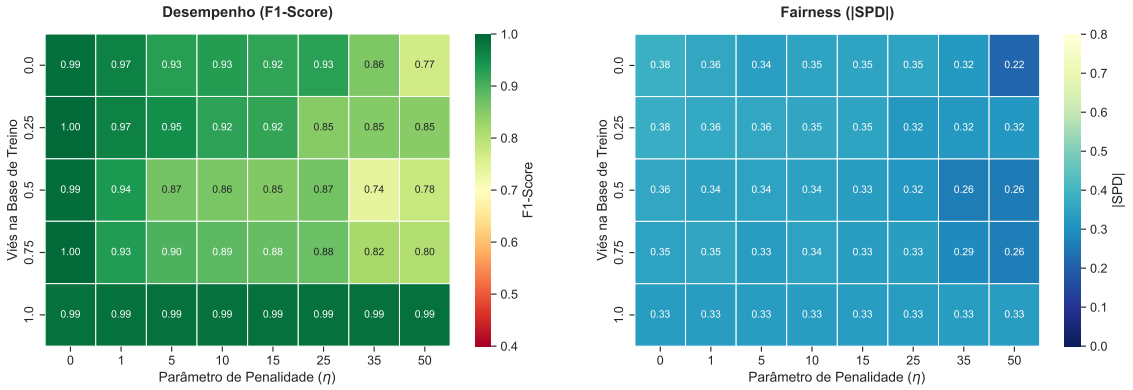

Figura 3. Heatmaps de F1-Score e abs_SPD por nível de viés da base de treinamento versus parâmetro η, médias sobre todas as bases de teste. Valores mais claros no heatmap de abs_SPD indicam maior disparidade.

A comparação direta entre $\eta = 0$ e $\eta = 35$ na Figura 4 ilustra a troca entre desempenho e equidade: à medida que o regularizador avança, as células de maior abs_SPD escurecem de forma não uniforme. Certas combinações de bases respondem bem à penalidade, enquanto outras permanecem praticamente inalteradas, evidenciando que a capacidade do Prejudice Remover depende fortemente do viés estrutural da base de treinamento.

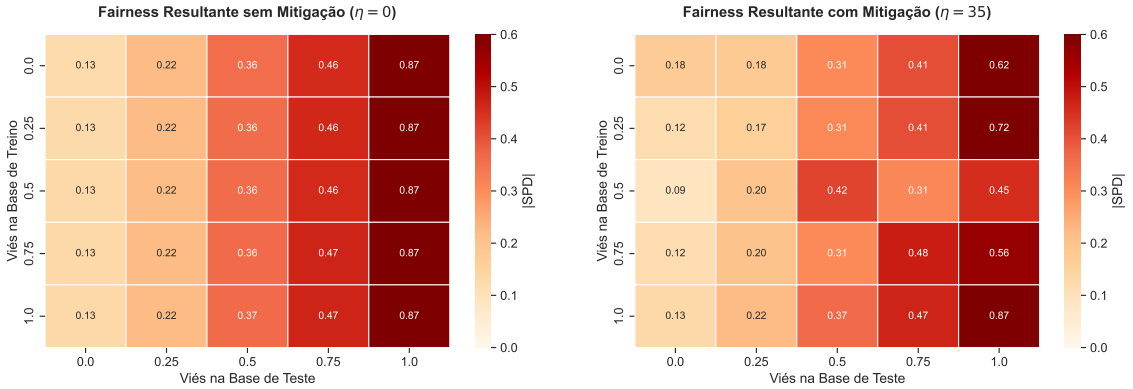

Figura 4. Matrizes de abs_SPD por par de bases (viés treino $\times$ viés teste) para $\eta = 0$ (esquerda) e $\eta = 35$ (direita). A redução de disparidade é mais expressiva nas bases PD com alto viés de treinamento; as combinações envolvendo GS respondem pouco ao regularizador.

A Figura 5 detalha a degradação simultânea de recall, precisão e F1 conforme η aumenta. O recall se mantém mais estável que a precisão: em $\eta = 50$, recall $= 0.893$ frente a precisão $= 0.782$, sugerindo que o regularizador torna o modelo mais cauteloso na sinalização de fraude sem perder tanto na detecção de casos reais.

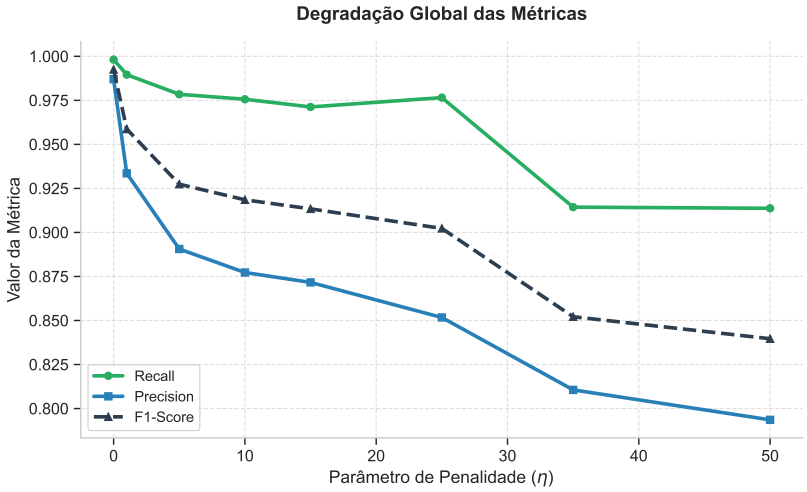

Figura 5. Degradação global de recall, precisão e F1-Score em função de η. O recall decresce mais lentamente que a precisão, indicando que a penalidade de equidade afeta principalmente a tendência do modelo de sinalizar transações como fraudulentas.

Por fim, a capacidade de generalização do modelo frente a diferentes distribuições de viés também é afetada pelo regularizador. A Figura 6 ilustra o comportamento para F1-Score e abs_SPD ao longo do parâmetro η, separando os resultados entre predições feitas na mesma série da base original e predições feitas em uma série distinta. Fica evidente que o viés aprendido generaliza de forma assimétrica: modelos avaliados em séries diferentes daquelas em que foram treinados apresentam disparidade consistentemente maior.

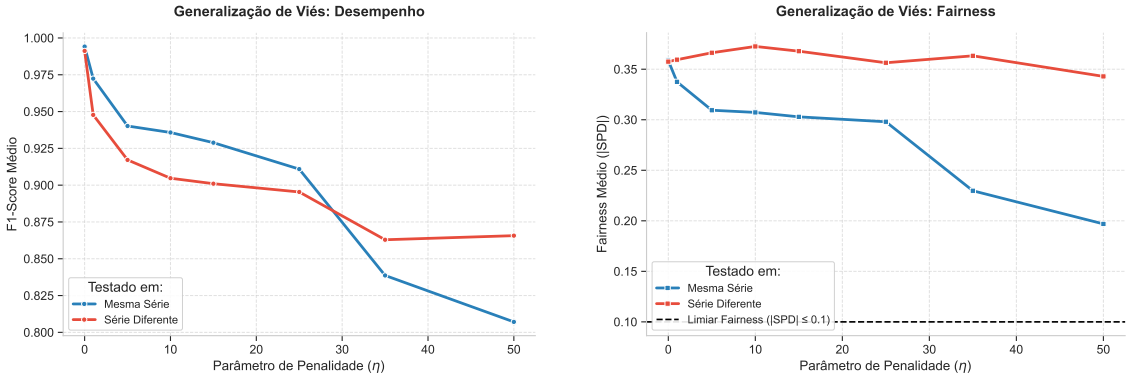

Figura 6. F1-Score e abs_SPD em função do parâmetro η, desagregados pelo cruzamento de séries: modelos avaliados na mesma série de origem versus avaliados em uma série distinta. Pares de séries distintas tendem a apresentar maior disparidade, evidenciando que o viés aprendido generaliza de forma assimétrica entre PD e GS.

4.3. Efeito do Volume de Dados de Treinamento

A Tabela 1 reúne as médias globais para os cinco volumes testados. O F1 cresceu de 0.9777 (1.000 amostras) a 0.9911 (10.000 amostras), ganho de apenas 0.0134, menos de 1.4% relativo. A precisão acompanhou esse crescimento de forma mais consistente

(+0.025), enquanto o recall permaneceu estável (variação < 0.001). Esse padrão sugere que, a partir de aproximadamente 1.000 amostras balanceadas, o modelo já captura os principais padrões preditivos; volume adicional refina a precisão em casos marginais sem ampliar substancialmente a detecção.

Tabela 1. Médias globais por volume de treinamento (Regressão Logística balanceada, 10 features).

Volume	F1	Precision	Recall	abs_SPD	DI
1.000	0.9777	0.9593	0.9972	0.3515	0.7225
2.500	0.9837	0.9702	0.9977	0.3548	0.7206
5.000	0.9882	0.9784	0.9982	0.3569	0.7196
7.500	0.9899	0.9820	0.9981	0.3575	0.7193
10.000	0.9911	0.9844	0.9980	0.3580	0.7190

No eixo da equidade, o resultado é contra-intuitivo: abs_SPD aumentou de 0.3515 para 0.3580 (+0.0065) à medida que o volume cresceu, e o DI afastou-se de 1.0 no mesmo sentido. Mais dados não corrigiram o viés aprendido; ao contrário, o modelo reproduziu com maior fidelidade os padrões desiguais presentes nos dados.

Um achado adicional merece atenção: com 10.000 amostras, bases de treinamento com maior viés sintético produziram F1 mais alto (v $= 0.75$: F1 $= 0.9958$) do que bases sem viés (v $= 0.00$: F1 $= 0.9886$). O viés introduzido aumenta a separabilidade entre classes no conjunto de treinamento, facilitando a tarefa preditiva, mas ao custo de abs_SPD mais elevado nas predições (v $= 0.00$: 0.384; v $= 0.75$: 0.346), pois os modelos treinados em dados mais enviesados tendem a generalizar esse viés para os conjuntos de teste.

4.4. Efeito do Conjunto de Atributos

A Tabela 2 apresenta os resultados para os quatro conjuntos de features. O salto mais expressivo ocorreu na transição de `transacional_2` para `tipo_temporal_4`: F1 subiu de 0.5322 para 0.9701 (+0.438), inteiramente conduzido pela adição de `is_cnab220`. Transações de crédito (CNAB $= 220$) concentram quase toda a fraude na base, tornando essa feature um preditor próximo de determinístico. Sem ela, o modelo operou com recall alto (0.9698) mas precisão drasticamente reduzida (0.3689), classificando a maioria das transações como fraude indiscriminadamente.

Tabela 2. Médias globais por conjunto de atributos (Regressão Logística balanceada, N $= 10.000$).

Conjunto	F1	Precision	Recall	abs_SPD	DI
`transacional_2`	0.5322	0.3689	0.9698	0.1866	0.7877
`tipo_temporal_4`	0.9701	0.9428	0.9993	0.3548	0.7175
`comportamental_6`	0.9844	0.9697	0.9997	0.3610	0.7145
`completo_10`	0.9911	0.9844	0.9980	0.3580	0.7190

As transições seguintes produziram retornos decrescentes. A adição das features comportamentais do titular (`tipo_temporal_4` $\rightarrow$ `comportamental_6`) acrescentou 0.014 de F1 e 0.027 de precisão, com recall quase inalterado. A inclusão dos z-scores por ramo (`completo_10`) contribuiu mais 0.007 de F1 e 0.015 de precisão, com leve queda de recall (-0.002). A normalização por ramo remove parte do efeito de grupo nas features, melhorando a generalização entre bases com distribuições distintas.

No eixo da equidade, o padrão foi não monótono. O conjunto `transacional_2` apresentou o menor abs_SPD (0.187), mas esse valor reflete a precisão colapsada, não equidade genuína: quando o modelo classifica quase tudo como fraude, a diferença entre grupos encolhe por indiferença. A adição de `is_cnab220` elevou o abs_SPD para 0.355, porque o modelo passou a diferenciar grupos de forma efetiva. Os dois conjuntos maiores oscilaram entre 0.355 e 0.361, sem tendência clara, confirmando que atributos adicionais não mitigam o viés estrutural dos dados.

4.5. Comparação de Métodos de Mitigação

A Tabela 3 compara os quatro métodos sobre o conjunto de 9 features (sem `is_cnab220`, cuja presença tornaria o problema preditivo quase trivial).

Tabela 3. Médias globais por método de mitigação (9 features, N $= 10.000$).

Método	F1	Precision	Recall	abs_SPD	DI
LR sem mitigação	**0.9663**	**0.9615**	0.9718	0.3425	0.7271
LR balanceado	0.9616	0.9398	0.9850	0.3450	0.7252
LR reponderado	0.9608	0.9374	**0.9861**	0.3433	0.7254
Prejudice Remover ($\eta = 10$)	0.8857	0.8341	0.9599	**0.3323**	0.6970

O modelo sem balanceamento obteve o melhor F1 (0.9663) e a maior precisão (0.9615), porém o menor recall (0.9718) entre os métodos LR. Isso reflete o comportamento esperado: sem forçar equilíbrio entre classes, o modelo é mais conservador na sinalização de fraude. O abs_SPD (0.3425) ficou abaixo do LR balanceado, resultado que indica que o balanceamento redistribui erros de forma simétrica entre classes, mas não entre grupos sensíveis.

O LR balanceado maximizou o recall (0.9850) entre os modelos LR, ao custo de menor precisão e F1. O abs_SPD (0.3450) foi o mais alto dos quatro métodos, confirmando que o balanceamento por classe não reduz a disparidade de predição entre grupos.

A reponderação de Kamiran e Calders produziu resultados praticamente idênticos ao LR balanceado: F1 -0.0007, recall +0.0011 e abs_SPD -0.0017. A diferença de equidade situou-se na terceira casa decimal, indicando que as duas abordagens de pré-processamento são intercambiáveis neste contexto.

O Prejudice Remover com $\eta = 10$ foi o único método a reduzir abs_SPD de forma perceptível: 0.3323 (-0.013 em relação ao LR balanceado). Em contrapartida, F1 caiu para 0.8857 (-0.076) e precisão para 0.8341 (-0.106). O comportamento por nível de viés é não monótono: a maior redução de abs_SPD ocorreu em $v = 0$ (-0.042 em relação ao LR balanceado), enquanto em $v = 0.75$ o ganho de equidade foi mínimo (-0.003) com queda

de F1 de -0.114, o pior custo-benefício de todos os cenários. Em $v = 1.0$, o Prejudice Remover passou a atuar como LR puro (*fallback* por ausência de grupos em algumas bases), produzindo resultado idêntico ao LR balanceado. A resposta ao regularizador também diferiu entre séries: a série PD respondeu com redução de F1 de 0.9572 para 0.8199 (-0.138) e redução de abs_SPD de 0.3234 para 0.3099 (-0.014), enquanto a série GS cedeu apenas 0.0145 de F1 com redução de abs_SPD de apenas 0.012. Nenhum método atingiu DI ≥ 0.8 em média.

5. Discussão

Os resultados permitem organizar as respostas às perguntas de pesquisa em torno de três eixos.

Volume de dados. A partir de 1.000 amostras balanceadas, o modelo já produziu F1 $= 0.977$, desempenho altamente competitivo. Volume adicional trouxe ganhos marginais e decrescentes em F1, sem nenhum benefício para a equidade; ao contrário, abs_SPD cresceu de forma contínua com o volume (+0.007 de 1.000 a 10.000 amostras). O modelo simplesmente aprendeu os padrões desiguais com maior fidelidade à medida que mais exemplos foram fornecidos. Esse resultado, alinhado com os achados de [Zhang and Harman 2021] sobre o efeito do tamanho do conjunto de treinamento, indica que mais dados podem acentuar levemente o viés aprendido, e que um volume maior não implica automaticamente maior injustiça, mas também não corrige o viés estrutural.

Seleção de atributos. Adicionar features melhorou sistematicamente o F1, mas não reduziu o viés estrutural. O valor mínimo de abs_SPD no conjunto `transacional_2` decorreu da indiferença do modelo, não de equidade real. A partir da adição de `is_cnab220`, o abs_SPD estabilizou em torno de 0.355–0.361, independentemente de quantos atributos foram incluídos. Mais atributos não garantem maior justiça, e os ganhos de precisão não foram acompanhados por ganhos proporcionais de equidade. Isso contrasta com a conclusão de [Zhang and Harman 2021] de que conjuntos de features mais ricos tendem a reduzir o viés, diferença que pode ser atribuída ao caráter sintético e ao alto nível de correlação entre o atributo sensível e a variável alvo nas bases utilizadas.

Métodos de mitigação. O balanceamento melhorou recall, mas elevou ligeiramente o abs_SPD em relação ao modelo não balanceado (+0.003), confirmando que o impacto na equidade é limitado e pode ser contraproducente. A reponderação ofereceu a melhor equidade entre os modelos LR, mas com diferença insignificante (-0.002 de abs_SPD), e as melhorias não foram significativas. O Prejudice Remover foi a única técnica com redução perceptível de abs_SPD (-0.013), mas com custo expressivo de F1 (-0.076) e comportamento errático por série e nível de viés. O limiar DI ≥ 0.8 não foi atingido por nenhum método em média, sendo alcançado apenas no subconjunto da série PD com $\eta = 50$, que ao mesmo tempo apresentou queda de F1 para 0.702.

Em conjunto, os resultados indicam que o viés observado nas predições é predominantemente estrutural, originado na correlação entre o atributo sensível e a variável alvo nos próprios dados, e resistente às técnicas de mitigação convencionais. Intervenções que não alteram essa correlação de base, como balanceamento e reponderação, produzem efeitos marginais. O Prejudice Remover, ao penalizar diretamente a dependência entre predições e grupo sensível, consegue reduções perceptíveis, mas à custa da performance preditiva e de forma inconsistente entre contextos.

6. Conclusão

Este trabalho investigou como o viés nos dados de treinamento e as escolhas de modelagem afetam a equidade de modelos de detecção de fraudes em transações financeiras. Três conjuntos de experimentos foram conduzidos sobre dez bases com viés sintético controlado, cobrindo perguntas de pesquisa relacionadas a volume de dados, seleção de atributos e técnicas de mitigação.

Os achados convergem para uma conclusão central: o viés de predição é estrutural e resistente às técnicas convencionais de mitigação. Aumentar o volume de dados não corrigiu a disparidade entre grupos, apenas a agravou levemente. Adicionar atributos melhorou a performance preditiva, mas não reduziu o abs_SPD a partir do momento em que o modelo passou a distinguir os grupos de forma efetiva. Entre os métodos de mitigação, apenas o Prejudice Remover produziu redução perceptível de abs_SPD, ao custo de queda expressiva de F1 e com comportamento inconsistente entre as séries PD e GS. Nenhum método atingiu o limiar DI ≥ 0.8 em média.

Esses resultados têm implicações práticas diretas: em domínios onde o viés está fortemente correlacionado com a variável alvo, como ocorre nas séries PD das bases utilizadas, intervenções de mitigação aplicadas apenas na etapa de modelagem têm alcance limitado. A correção do viés exige atenção desde a coleta e curadoria dos dados, incluindo estratégias de amostragem que garantam representação adequada dos grupos sensíveis em ambas as classes.

Referências

[Barocas and Selbst 2016] Barocas, S. and Selbst, A. D. (2016). Big data's disparate impact. *California Law Review*, 104:671–732.

[Gomes et al. 2026] Gomes, L. V. D. S., Silva, F. M. S., Guerra, P. T. S., and Silva, R. M. d. (2026). am-project: Código e experimentos para detecção de fraudes financeiras. `https://github.com/lucasvictoor/am-project`.

[Kamiran and Calders 2012] Kamiran, F. and Calders, T. (2012). Data preprocessing techniques for classification without discrimination. *Knowledge and Information Systems*, 33(1):1–33.

[Kamishima et al. 2012] Kamishima, T., Akaho, S., Asoh, H., and Sakuma, J. (2012). Fairness-aware classifier with prejudice remover regularizer. In *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, pages 35–50, Berlin, Heidelberg. Springer.

[Zhang and Harman 2021] Zhang, J. M. and Harman, M. (2021). "Ignorance and Prejudice" in Software Fairness. In *Proceedings of the 43rd International Conference on Software Engineering (ICSE)*, pages 1436–1447. IEEE.